Universidad Autónoma de Santo Domingo

UASD

Facultad de Ciencias - Escuela de Informática

División de Postgrado y Educación Permanente

INF-8239 Ciencia de Datos II

Trabajo final - Modalidad A

Dígitos manuscritos robustos

Visión por computadora

Presentado por:

Victor Manuel Perez Padilla

Matrícula: 100801946

Tema: TF.19

Santo Domingo, República Dominicana

Octubre de 2026

Resumen

Este proyecto compara un baseline de centroides con una CNN pequeña para clasificar dígitos manuscritos de MNIST y estudiar el efecto de ruido gaussiano, rotación y su combinación. La CNN obtuvo 98.17% de accuracy en imágenes limpias y 94.84% bajo la combinación de perturbaciones, frente a 82.03% y 71.55% del baseline, respectivamente. La conclusión accionable es usar la CNN dentro del dominio evaluado, manteniendo la advertencia de que MNIST no representa por sí solo documentos manuscritos reales.

Contenido del informe

1. Introducción y problema	3
2. Objetivos	3
3. Datos y preparación	4
4. Metodología e implementación	4
5. Resultados	5
6. Limitaciones y uso responsable	6
7. Conclusiones	6

Palabras clave: visión por computadora, MNIST, CNN, robustez, ruido, rotación, reproducibilidad.

1. Introducción y problema

La clasificación de dígitos manuscritos es un problema controlado de visión por computadora que permite estudiar la relación entre representación visual, capacidad predictiva y robustez. El riesgo metodológico central de este trabajo es confundir un buen resultado en imágenes limpias con un modelo resistente a cambios de captura.

La pregunta de investigación es: ¿hasta qué punto una CNN pequeña mejora a un baseline al clasificar dígitos manuscritos con ruido gaussiano, rotación o ambas perturbaciones, manteniendo una latencia adecuada para una demostración local?

2. Objetivos

Objetivo general

Comparar un baseline reproducible con una CNN pequeña para determinar cuál ofrece mejor equilibrio entre accuracy, robustez y latencia en MNIST.

Objetivos específicos

1. Definir un contrato de entrada para imágenes 28x28 en escala de grises. 2. Entrenar y evaluar ambos modelos con una semilla registrada. 3. Medir el desempeño en imágenes limpias, con ruido, con rotación y con ambas perturbaciones. 4. Documentar limitaciones, pruebas y una conclusión accionable.

3. Datos y preparación

Se utilizó MNIST, descargado mediante el mecanismo de Keras y conservado localmente en una caché excluida del repositorio. La partición oficial contiene 60,000 imágenes de entrenamiento y 10,000 de prueba. Las imágenes se convierten a flotantes, se normalizan al rango [0, 1] y se representan con un canal explícito.

Las perturbaciones se aplican únicamente al conjunto de prueba ya separado: ruido gaussiano con desviación estándar 0.20, rotación de 15 grados y la composición de ambos

escenarios. Esto evita mezclar artificialmente escenarios de evaluación con el entrenamiento.

4. Metodología e implementación

El baseline calcula un centroide por clase a partir de los píxeles aplanados y asigna cada imagen a la clase con menor distancia media cuadrática. La CNN utiliza dos capas convolucionales pequeñas, pooling, una capa densa y una salida softmax de diez clases. Se entrenó con Adam, batch de 128 y dos épocas.

La semilla experimental fue 8239. El flujo se ejecuta desde scripts/run_experiment.py, registra la versión de Python, plataforma, TensorFlow, tamaño de las particiones, métricas y latencia en output/results/metrics.json. El repositorio reproducible se encuentra en GitHub.

5. Resultados

La ejecución se realizó con Python 3.14.0, TensorFlow 2.22.0-rc0, 60,000 muestras de entrenamiento y 10,000 muestras de prueba.

Tabla 1

Exactitud y latencia por escenario de evaluación

Modelo	Limpio	Ruido	Rotación	Ruido + rotación	ms/muestra
Baseline centroides	82.03%	82.45%	72.41%	71.55%	0.021
CNN pequeña	98.17%	96.97%	95.95%	94.84%	0.352

La CNN mejora 15.14 puntos porcentuales sobre el baseline en limpio y 23.29 puntos en la combinación de ruido y rotación. Su caída desde limpio es de 3.33 puntos, mientras que la del baseline es de 10.48 puntos. Esto aporta evidencia a favor de la CNN dentro de los escenarios evaluados, sin justificar generalización fuera de ellos.

6. Pruebas y reproducibilidad

La suite automatizada contiene seis pruebas aprobadas: contrato de imágenes y etiquetas, rechazo de formas incorrectas, reproducibilidad y rango del ruido, preservación de forma en rotación, reporte de escenarios y medición de latencia. El enlace del repositorio es:

https://github.com/vmperez997-max/Trabajo-final

7. Análisis de errores y robustez

El escenario más exigente fue la combinación de ruido y rotación. La CNN alcanzó 94.84%, mientras que el baseline cayó a 71.55%. La diferencia indica que la CNN aprende representaciones espaciales más estables para las perturbaciones controladas. Sin embargo, accuracy agregada no muestra qué clases específicas concentran los errores; por eso se recomienda incorporar una matriz de confusión y revisión visual por clase en una iteración posterior.

8. Limitaciones y uso responsable

MNIST no representa toda la variabilidad de escritura manuscrita, perspectiva, iluminación, compresión, tinta, papel o resolución de documentos reales. El ruido gaussiano y la rotación son aproximaciones controladas. La latencia observada depende del CPU y no debe interpretarse como garantía para otro equipo.

El modelo debe abstenerse de conclusiones fuera del contrato de entrada y no debe utilizarse como OCR documental general sin validación externa. La Model Card y la declaración de uso de IA acompañan el repositorio.

9. Green AI y trazabilidad

Se utilizó una CNN pequeña, dos épocas y ejecución en CPU, limitando el costo computacional del experimento. La configuración, semilla, dependencias, métricas y código quedan registrados para facilitar repetición y auditoría.

10. Conclusiones

Para el alcance individual de este proyecto, la CNN pequeña es el modelo recomendado: obtuvo mayor accuracy en limpio, menor degradación relativa bajo las perturbaciones evaluadas y una latencia local inferior a 1 ms por muestra. La recomendación se detiene o debe escalarse cuando la imagen no cumpla el contrato, cuando se use un dominio distinto de MNIST o cuando se necesite evidencia de desempeño por clase en datos externos.

Referencias

Yann LeCun, Corinna Cortes y Christopher Burges. MNIST handwritten digit database. http://yann.lecun.com/exdb/mnist/

TensorFlow Keras. MNIST dataset API. https://www.tensorflow.org/api_docs/python/tf/keras/datasets/mnist

Repositorio del proyecto. https://github.com/vmperez997-max/Trabajo-final