**Universidad Autónoma de Santo Domingo**

**UASD**

Facultad de Ciencias - Escuela de Informática

División de Postgrado y Educación Permanente

**INF-8239 Ciencia de Datos II**

**Trabajo final - Modalidad A**

# Dígitos manuscritos robustos

Visión por computadora

Presentado por:

Victor Manuel Perez Padilla

Matrícula: 100801946

Tema: TF.19

Santo Domingo, República Dominicana

Octubre de 2026

## Resumen

Este proyecto compara un baseline de centroides con una CNN pequeña para clasificar dígitos manuscritos de MNIST y estudiar el efecto de ruido gaussiano, rotación y su combinación. La CNN obtuvo 98.17% de accuracy en imágenes limpias y 94.84% bajo la combinación de perturbaciones, frente a 82.03% y 71.55% del baseline, respectivamente. La conclusión accionable es usar la CNN dentro del dominio evaluado, manteniendo la advertencia de que MNIST no representa por sí solo documentos manuscritos reales.


## Contenido del informe


| | |
|---|---|
| 1. Introducción y problema | 3 |
| 2. Objetivos | 3 |
| 3. Datos y preparación | 4 |
| 4. Metodología e implementación | 4 |
| 5. Resultados | 5 |
| 6. Limitaciones y uso responsable | 6 |
| 7. Conclusiones | 6 |


Palabras clave: visión por computadora, MNIST, CNN, robustez, ruido, rotación, reproducibilidad.

## 1. Introducción y problema

La clasificación de dígitos manuscritos es un problema controlado de visión por computadora que permite estudiar la relación entre representación visual, capacidad predictiva y robustez. El riesgo metodológico central de este trabajo es confundir un buen resultado en imágenes limpias con un modelo resistente a cambios de captura.

La pregunta de investigación es: ¿hasta qué punto una CNN pequeña mejora a un baseline al clasificar dígitos manuscritos con ruido gaussiano, rotación o ambas perturbaciones, manteniendo una latencia adecuada para una demostración local?

## 2. Objetivos

### Objetivo general

Comparar un baseline reproducible con una CNN pequeña para determinar cuál ofrece mejor equilibrio entre accuracy, robustez y latencia en MNIST.

### Objetivos específicos

1. Definir un contrato de entrada para imágenes 28x28 en escala de grises. 2. Entrenar y evaluar ambos modelos con una semilla registrada. 3. Medir el desempeño en imágenes limpias, con ruido, con rotación y con ambas perturbaciones. 4. Documentar limitaciones, pruebas y una conclusión accionable.

## 3. Datos y preparación

Se utilizó MNIST, descargado mediante el mecanismo de Keras y conservado localmente en una caché excluida del repositorio. La partición oficial contiene 60,000 imágenes de entrenamiento y 10,000 de prueba. Las imágenes se convierten a flotantes, se normalizan al rango [0, 1] y se representan con un canal explícito.

Las perturbaciones se aplican únicamente al conjunto de prueba ya separado: ruido gaussiano con desviación estándar 0.20, rotación de 15 grados y la composición de ambos

escenarios. Esto evita mezclar artificialmente escenarios de evaluación con el entrenamiento.

## 4. Metodología e implementación

El baseline calcula un centroide por clase a partir de los píxeles aplanados y asigna cada imagen a la clase con menor distancia media cuadrática. La CNN utiliza dos capas convolucionales pequeñas, pooling, una capa densa y una salida softmax de diez clases. Se entrenó con Adam, batch de 128 y dos épocas.

La semilla experimental fue 8239. El flujo se ejecuta desde scripts/run_experiment.py, registra la versión de Python, plataforma, TensorFlow, tamaño de las particiones, métricas y latencia en output/results/metrics.json. El repositorio reproducible se encuentra en GitHub.

## 5. Resultados

La ejecución se realizó con Python 3.14.0, TensorFlow 2.22.0-rc0, 60,000 muestras de entrenamiento y 10,000 muestras de prueba.

**Tabla 1**

*Exactitud y latencia por escenario de evaluación*

| Modelo | Limpio | Ruido | Rotación | Ruido + rotación | ms/muestra |
|---|---|---|---|---|---|
| Baseline centroides | 82.03% | 82.45% | 72.41% | 71.55% | 0.021 |
| CNN pequeña | 98.17% | 96.97% | 95.95% | 94.84% | 0.352 |

La CNN mejora 15.14 puntos porcentuales sobre el baseline en limpio y 23.29 puntos en la combinación de ruido y rotación. Su caída desde limpio es de 3.33 puntos, mientras que la del baseline es de 10.48 puntos. Esto aporta evidencia a favor de la CNN dentro de los escenarios evaluados, sin justificar generalización fuera de ellos.

## 6. Pruebas y reproducibilidad

La suite automatizada contiene seis pruebas aprobadas: contrato de imágenes y etiquetas, rechazo de formas incorrectas, reproducibilidad y rango del ruido, preservación de forma en rotación, reporte de escenarios y medición de latencia. El enlace del repositorio es:

https://github.com/vmperez997-max/Trabajo-final

## 7. Análisis de errores y robustez

El escenario más exigente fue la combinación de ruido y rotación. La CNN alcanzó 94.84%, mientras que el baseline cayó a 71.55%. La diferencia indica que la CNN aprende representaciones espaciales más estables para las perturbaciones controladas. Sin embargo, accuracy agregada no muestra qué clases específicas concentran los errores; por eso se recomienda incorporar una matriz de confusión y revisión visual por clase en una iteración posterior.

## 8. Limitaciones y uso responsable

MNIST no representa toda la variabilidad de escritura manuscrita, perspectiva, iluminación, compresión, tinta, papel o resolución de documentos reales. El ruido gaussiano y la rotación son aproximaciones controladas. La latencia observada depende del CPU y no debe interpretarse como garantía para otro equipo.

El modelo debe abstenerse de conclusiones fuera del contrato de entrada y no debe utilizarse como OCR documental general sin validación externa. La Model Card y la declaración de uso de IA acompañan el repositorio.

## 9. Green AI y trazabilidad

Se utilizó una CNN pequeña, dos épocas y ejecución en CPU, limitando el costo computacional del experimento. La configuración, semilla, dependencias, métricas y código quedan registrados para facilitar repetición y auditoría.

## 10. Conclusiones

Para el alcance individual de este proyecto, la CNN pequeña es el modelo recomendado: obtuvo mayor accuracy en limpio, menor degradación relativa bajo las perturbaciones evaluadas y una latencia local inferior a 1 ms por muestra. La recomendación se detiene o debe escalarse cuando la imagen no cumpla el contrato, cuando se use un dominio distinto de MNIST o cuando se necesite evidencia de desempeño por clase en datos externos.

## Referencias

Yann LeCun, Corinna Cortes y Christopher Burges. MNIST handwritten digit database. http://yann.lecun.com/exdb/mnist/

TensorFlow Keras. MNIST dataset API. https://www.tensorflow.org/api_docs/python/tf/keras/datasets/mnist

Repositorio del proyecto. https://github.com/vmperez997-max/Trabajo-final